

INFORME DE AVANCE DE PROYECTO

- **Sistema de Apoyo a la Toma de Decisiones para la Retención de Clientes** (Telco Customer Churn)
- **Autores:** Jorge Emilio Quiroga Lopez, Jacqueline Zapata Treviño, Andrés Bernardo Vallejo Herrera
- **Institución:** Universidad Tecmilenio
- **Programa:** Ingeniería en Desarrollo de Software
- **Fecha de Ejecución:** 1 de septiembre de 2026
- **Entorno:** Python 3.10 | Google Colab

1. DESCRIPCIÓN DEL PROBLEMA Y CONTEXTO ORGANIZACIONAL

1.1 Contexto Organizacional

Una empresa que ofrece servicios por suscripción ha experimentado un incremento constante en la tasa de cancelación (churn) de sus usuarios. Actualmente, la organización aplica estrategias de retención genéricas de forma masiva (e.g., descuentos generalizados o campañas globales), lo que genera altos costos operativos y baja efectividad, al no distinguir cuáles clientes presentan un riesgo real e inminente de cancelación.

1.2 Necesidad Organizacional

La organización requiere un sistema analítico basado en Machine Learning que permita:

1. Estimación probabilística del riesgo de abandono para cada cliente a partir de su perfil contractual y de uso.
2. Identificación y priorización de los clientes con mayor probabilidad de abandono para focalizar el seguimiento.
3. Generación de evidencia cuantitativa que guíe al equipo comercial y de servicio al cliente.

1.3 Unidad de Análisis y Tipo de Problema

- **Unidad de Análisis:** Cada fila del dataset representa a un cliente individual con su respectivo historial de contratación, servicios y patrón de pago.
- **Tipo de Problema:** Clasificación binaria.
- **Clase Positiva (1):** Cliente que abandona la empresa (Exited = 1 o Churn = Yes).
- **Clase Negativa (0):** Cliente que permanece activo en la empresa (Exited = 0 o Churn = No).

1.4 Decisión Apoyada y Usuarios Potenciales

- **Usuarios Potenciales:** Gerencia de Fidelización y Retención, Equipos de Atención al Cliente y Analistas de Inteligencia de Negocios (BI).

- Decisión Apoyada: Orientar intervenciones proactivas (e.g., llamadas de fidelización, revisión de contratos, planes de incentivos personalizados) hacia la bolsa de clientes de alto riesgo.

1.5 Justificación del Uso como Herramienta de Análisis (No Automatizada) y Riesgo de Uso Incorrecto

El modelo se diseña estrictamente como un sistema de apoyo a la toma de decisiones (Human-in-the-loop).

- Riesgo de uso incorrecto: Interpretar la probabilidad emitida por el algoritmo como una certeza absoluta o utilizarla para aplicar decisiones desfavorables de manera automatizada (tales como restringir beneficios, aplicar penalizaciones contractuales o modificar tarifas al alza) creará un efecto adverso (self-fulfilling prophecy), acelerando la cancelación del cliente e introduciendo sesgos punitivos.
- Justificación de control: Las predicciones representan patrones estadísticos pasados, no comportamientos futuros garantizados. La intervención humana es indispensable para validar el contexto cualitativo del usuario antes de aplicar una acción comercial.

2. SELECCIÓN Y DATOS DEL DATASET

Elemento	Información Registrada
Nombre del dataset	Telco Customer Churn / Bank Churn Modeling
Fuente	Kaggle (BlastChar / Churn_Modelling Dataset)
Liga de acceso	https://www.kaggle.com/datasets/blastchar/telco-customer-churn
Fecha de consulta	1 de septiembre de 2026
Número de observaciones	10,000 registros
Número de variables	14 columnas originales
Formato original del archivo	CSV (Churn_Modelling.csv / Telco-Customer-Churn.csv)
Variable objetivo	Exited (Binaria: 0 = Permanece, 1 = Abandona)

3. FORMULACIÓN DE LA PREGUNTA DE ANÁLISIS

¿Cómo pueden utilizarse los datos históricos contractuales, demográficos y de uso de los clientes para identificar de manera anticipada aquellos casos con mayor riesgo de abandono y apoyar acciones de retención prioritarias mediante un flujo reproducible de aprendizaje automático?

4. DICCIONARIO DE VARIABLES

Nombre de la Variable	Descripción	Tipo Original	Tipo Analítico	Rol	Unidad / Escala	Valores Faltantes	Tratamiento Previsto
RowNumber	Índice continuo de la fila	int64	Identificador	Excluida	[1, 10000]	0 (0%)	Eliminación
CustomerId	Identificador único del cliente	int64	Identificador	Excluida	Código entero	0 (0%)	Eliminación
Surname	Apellido del titular	object	Categorica / Texto	Excluida	Texto	0 (0%)	Eliminación
CreditScore	Puntaje crediticio del cliente	int64	Numérica Continua	Predictora	Puntos [350, 850]	0 (0%)	Escalamiento (StandardScaler)
Geography	País de residencia del cliente	object	Categorica Nominal	Predictora	France, Spain, Germany	0 (0%)	Codificación (OneHotEncoder)
Gender	Género del cliente	object	Binaria Categorica	Predictora	Female, Male	0 (0%)	Codificación (OneHotEncoder)

Age	Edad del cliente en años	int64	Numérica Discreta	Predictora	Años [18, 92]	0 (0%)	Escalamiento (StandardScaler)
Tenure	Antigüedad (meses/años) con la empresa	int64	Numérica Discreta	Predictora	Rango [0, 10]	0 (0%)	Escalamiento (StandardScaler)
Balance	Saldo disponible en la cuenta	float64	Numérica Continua	Predictora	Moneda local	0 (0%)	Escalamiento (StandardScaler)
NumOfProducts	Número de productos contratados	int64	Numérica Discreta	Predictora	Entero [1, 4]	0 (0%)	Escalamiento (StandardScaler)
HasCrCard	Posee tarjeta de crédito activa	int64	Binaria	Predictora	{0, 1}	0 (0%)	Mantiene codificación directa
IsActiveMember	Estatus de miembro activo	int64	Binaria	Predictora	{0, 1}	0 (0%)	Mantiene codificación directa
EstimatedSalary	Salario estimado del cliente	float64	Numérica Continua	Predictora	Moneda local	0 (0%)	Escalamiento (StandardScaler)

Exited	Indicador de abandono del cliente	int64	Binaria	Objetivo (y)	{0, 1}	0 (0%)	Mantiene como entero binario
--------	-----------------------------------	-------	---------	--------------	--------	--------	------------------------------

- Justificación de Exclusión:** RowNumber, CustomerId y Surname se excluyeron debido a que son identificadores arbitrarios o datos nominales únicos. No poseen poder de generalización e introducen riesgo de memorización/sobreajuste (overfitting).

5. CARGA, EXPLORACIÓN INICIAL Y DIAGNÓSTICO DE CALIDAD DE DATOS

5.1 Hallazgos de la Exploración Inicial

Al realizar la inspección técnica en Python sobre las 10,000 observaciones:

- Dimensiones: 10,000 filas x 14 columnas.
- Valores Faltantes: 0 nulos detectados en la estructura general.
- Registros Duplicados: 0 filas duplicadas.
- Distribución de Objetivo (Exited): 7,963 clientes retenidos (0) y 2,037 clientes que abandonaron (1).

5.2 Tabla de Diagnóstico de Calidad de Datos

Problema Detectado	Variable Afectada	Evidencia	Posible Impacto	Tratamiento Propuesto	Justificación
Identificadores No Informativos	RowNumber, CustomerId, Surname	Variables únicas con cardinalidad casi igual a N.	Memorización y ruido en los modelos.	Eliminación de columnas.	No representan comportamiento del cliente.
Diferencias de Escala Numérica	CreditScore, Age, Balance, EstimatedSalary	Rangos heterogéneos (e.g., Edad [18-92] vs Saldo [0-250k]).	Sesgo en Regresión Logística y modelos basados	Estandarización (StandardScaler) en Pipeline.	Normaliza la magnitud a mu=0, sigma=1 sin fuga de datos.

			en distancias.		
Variables Categóricas Nominales	Geography, Gender	Valores de texto ("France", "Spain", "Female").	Incompatibilidad directa con algoritmos matemáticos.	Codificación One-Hot (OneHotEncoder).	Transforma a dummies numéricas sin imponer orden implícito.
Desbalance de Clases	Exited	Proporción 79.63% (Clase 0) vs 20.37% (Clase 1).	Inclinación a predecir la clase mayoritaria si se evalúa solo con Accuracy.	Estratificación en split y evaluación con Recall/F1/ROC-AUC.	Garantiza que las métricas reflejen la detección real de la clase positiva.

6. ANÁLISIS EXPLORATORIO DE DATOS (EDA) Y REVISIÓN DE DESBALANCE

6.1 Relaciones Clave con el Abandono

- 1. **Edad (Age):** El gráfico de caja (*Boxplot*) evidencia que los clientes que abandonan presentan una mediana de edad significativamente más alta (~45 años) en comparación con los clientes retenidos (~36 años).
- 2. **Geografía (Geography):** Los clientes en Alemania presentan una tasa promedio de abandono sensiblemente superior (aproximadamente 32%) a la de Francia o España (~16%).
- 3. **Cantidad de Productos (NumOfProducts):** Existe una marcada no-linealidad; los clientes con 3 o 4 productos presentan tasas de cancelación masivas (>80%), sugiriendo empaquetamientos de servicios insatisfactorios.

6.2 Análisis del Desbalance de Clases

- **Frecuencias:** Clase 0 (7,963 obs. / 79.63%) | Clase 1 (2,037 obs. /20.37%).
- **Efecto en la Evaluación:** Un modelo ingenuo que clasifique a todos los clientes como "No Abandona" obtendría un 79.63% de Accuracy sin haber detectado a un solo cliente en riesgo.

- **Decisión Metodológica:** En esta fase no se aplicaron técnicas de remuestreo (SMOTE o Undersampling) sobre el dataset completo para evitar alterar las probabilidades calibradas originales y prevenir fuga de información. La estrategia adoptada fue la estratificación en la partición y el enfoque en métricas inmunes al desbalance (*Recall*, *F1-Score*, *ROC-AUC*).


7. ANÁLISIS DE FUGAS DE INFORMACIÓN (DATA LEAKAGE)

Se evaluó la temporalidad y disponibilidad de cada atributo al momento de realizar la predicción en un entorno de producción:

- **Evaluación de Atributos:** Variables como Balance, NumOfProducts, IsActiveMember y CreditScore representan el estado del cliente en el período activo inmediatamente anterior a la ventana de observación del abandono. Ninguna variable del dataset se genera posteriormente a la cancelación del contrato ni revela directamente la etiqueta Exited.
- **Conclusión Explícita:** No existe presencia de fuga de información en el conjunto de variables seleccionadas para el modelado.

8. ESTRATEGIA DE PARTICIÓN DE DATOS

Para evaluar la capacidad de generalización del modelo, los datos limpios (N=10,000) se dividieron en tres conjuntos independientes manteniendo la distribución original de la clase positiva mediante estratificación.



Parámetro	Valor Utilizado
Proporción de Entrenamiento	70% (N = 7,000)
Proporción de Validación	15% (N = 1,500)
Proporción de Prueba (Holdout)	15% (N = 1,500)
Semilla Aleatoria (SEED)	42
Método de Estratificación	<code>stratify = y</code> (conserva la proporción ~20.37% en todas las particiones)

9. PIPELINE DE PREPROCESAMIENTO Y MODELOS DESPLEGADOS

9.1 Arquitectura del Pipeline Reproducible

Se diseñó un ColumnTransformer encapsulado en un Pipeline de Scikit-Learn:

- **Ruta Numérica:** Estandarización mediante `StandardScaler()` aplicada a `CreditScore`, `Age`, `Tenure`, `Balance`, `NumOfProducts`, `EstimatedSalary`.
- **Ruta Categórica:** Codificación `OneHotEncoder(drop='first', handle_unknown='ignore')` aplicada a `Geography` y `Gender`.
- **Prevención de Leakage:** Los parámetros de escalamiento (`mu`, `sigma`) y las categorías se aprenden exclusivamente con el conjunto de entrenamiento (`fit`) y solo se transforman (`transform`) los conjuntos de validación y prueba.

10. EVALUACIÓN DE MODELOS Y TABLA COMPARATIVA

Todos los modelos se entrenaron sobre el conjunto de entrenamiento (70%) y se evaluaron sobre el conjunto de validación (15%).

Modelo	Accuracy	Precision	Recall	F1-Score	ROC-AUC
DummyClassifier (Estrategia Prior)	0.7960	0.0000	0.0000	0.0000	0.5000
Regresión Logística (Baseline Interpretable)	0.8140	0.6023	0.1732	0.2690	0.7679
Random Forest (Modelo Ensamblado)	0.8660	0.7818	0.4216	0.5478	0.8491
Gradient Boosting (Modelo Secuencial Avanzado)	0.8647	0.7487	0.4673	0.5758	0.8617

11. ANÁLISIS DE ERRORES Y MATRIZ DE CONFUSIÓN

11.1 Interpretación de Errores Operativos

- **Falso Positivo (FP):** Cliente que el modelo clasifica con riesgo de abandono pero que en realidad permanece.
 - Costo Operativo: Incurrir en un gasto innecesario de retención (e.g., otorgar un descuento o enviar un obsequio). Es un costo marginal controlado.
- **Falso Negativo (FN):** Cliente clasificado como estable que en realidad cancela su contrato.
 - Costo Operativo: Pérdida total del valor de vida del cliente (Customer Lifetime Value - CLV) y del margen de ingresos futuros. Es el error más crítico para la organización.
 -

Conclusión sobre Métricas: El Recall mide la capacidad de capturar a los clientes que realmente abandonarán. Por lo tanto, el modelo óptimo debe maximizar el Recall manteniendo un F1-Score y ROC-AUC equilibrados, desestimando la selección basada únicamente en Accuracy.

12. ANÁLISIS DEL UMBRAL DE DECISIÓN

Tomando como referencia el modelo con mejor capacidad de separación de probabilidades (Gradient Boosting), se evaluó el impacto de ajustar el umbral de decisión operativo sobre la partición de validación:

Umbral (τ)	Precision	Recall	F1-Score	Observación Operativa
0.50 (Estándar)	0.7487	0.4673	0.5758	Alta precisión, pero deja escapar a más del 53% de los clientes en riesgo.
0.30 (Optimizado para Retención)	0.5310	0.7255	0.6130	Captura a más del 72% de los casos de abandono reales a costa de aumentar falsos positivos aceptables.

Conclusión: Ajustar el umbral a $t=0.30$ duplica la tasa de captura de clientes en riesgo, demostrando que la implementación del modelo depende de una decisión estratégica de negocio y no solo del parámetro computacional por defecto.

13. SELECCIÓN DEL MODELO PRELIMINAR

13.1 Tabla de Decisión

Criterio	Modelo Seleccionado	Justificación
Desempeño General	Gradient Boosting	Logró la mayor área bajo la curva ROC-AUC (0.8617).

Recall de Abandono	Gradient Boosting	Obtuvo el mayor Recall en el umbral por defecto (0.4673) y mejor respuesta al ajustar umbral (0.7255).
Equilibrio Precision-Recall	Gradient Boosting	Registró el F1-Score más elevado (0.5758).
Interpretabilidad	Regresión Logística	Aunque es más interpretable por sus coeficientes, su capacidad predictiva es insuficiente (Recall = 0.1732).
Riesgo Operativo	Gradient Boosting	Minimiza los Falsos Negativos (pérdida de clientes de alto valor).

- **Selección Final:** Se selecciona Gradient Boosting Classifier como la base técnica para evolucionar hacia la entrega final del proyecto.

14. PLAN DE MEJORA PARA LA ENTREGA FINAL

1. **Optimización de Hiperparámetros:** Realizar búsquedas sistemáticas mediante GridSearchCV / RandomizedSearchCV sobre el modelo Gradient Boosting (ajustando n_estimators, learning_rate, max_depth y min_samples_split).
2. **Validación Cruzada Estratificada:** Implementar K-Fold Stratified Cross-Validation (K=5) sobre el conjunto de entrenamiento para reducir la varianza de estimación.
3. **Ingeniería de Características:** Generar atributos interactivos (e.g., relación Balance/EstimatedSalary, interacciones entre Age y NumOfProducts).
4. **Técnicas de Balanceo Ajustadas:** Evaluar SMOTE o el ajuste de pesos de clase (scale_pos_weight) dentro del Pipeline de entrenamiento.
5. **Interpretabilidad Avanzada:** Integrar explicabilidad global y local mediante valores SHAP (SHapley Additive exPlanations) o LIME.
6. **Serialización del Pipeline:** Exportar el flujo completo entrenado en un archivo ejecutable binario (.joblib / .pkl).
7. **Monitoreo y Despliegue:** Construir una función de inferencia para datos no vistos y definir un plan de monitoreo para detectar sesgos o degradación (Data Drift).

15. TRAZABILIDAD Y ENTORNO DE EJECUCIÓN

15.1 Tabla de Trazabilidad Inicial

Elemento	Detalle de Registro
Dataset	Churn_Modelling.csv
Fuente	Kaggle - BlastChar / Bank Churn Dataset
Fecha de Consulta / Ejecución	1 de septiembre de 2026
Semilla Aleatoria (SEED)	42
Pipeline de Preprocesamiento	ColumnTransformer (StandardScaler + OneHotEncoder)
Baseline Evaluado	DummyClassifier(strategy='prior')
Modelos Comparados	Regresión Logística, Random Forest, Gradient Boosting
Métrica Principal de Selección	ROC-AUC y F1-Score / Recall
Entorno de Ejecución	Google Colab / Python 3.10
Archivo Principal	Notebook .ipynb ejecutado

15.2 Registro de Versiones del Entorno

- python: 3.10.x
- pandas: 2.2.2
- numpy: 1.26.4
- scikit-learn: 1.5.2
- seaborn: 0.13.2
- matplotlib: 3.9.2

16. CONCLUSIONES

- **Relevancia del Flujo Reproducible:** La estructuración del preprocesamiento dentro de un Pipeline encapsulado garantizó la separación estricta entre entrenamiento y validación, eliminando cualquier posibilidad de fuga de información por estandarización o codificación previa.
- **Limitaciones de la Accuracy:** Se comprobó experimentalmente que evaluar el problema únicamente mediante *Accuracy* resulta totalmente engañoso. El modelo baseline obtuvo una exactitud cercana al 80% sin tener ninguna utilidad analítica.
- **Impacto del Umbral de Decisión:** La selección del umbral no es un paso puramente técnico, sino una decisión estratégica del negocio. Ajustar el umbral operativo a $t=0.30$ permitió capturar el 72.55% de los clientes propensos a cancelar, maximizando la efectividad del equipo de retención.
- **Paso hacia la Implementación Operativa:** El modelo debe mantenerse como un insumo analítico complementario. La intervención humana sigue siendo indispensable para validar el contexto del cliente antes de desplegar acciones de fidelización.